Proyecto ML – Estimación de Precios Inmobiliarios

- Autores:
  - Milagros Abril
  - Pedro Herrero Bas
  - Manuel Ros Martínez

Objetivo del Proyecto

Predecir el precio de publicación (EUR) de viviendas de la empresa Tecnocasa mediante Machine Learning (regresión).

Utilidad

- Detectar anuncios **sobrevalorados** o **infravalorados**.
- Apoyar decisiones de **búsqueda** o **inversión**

Extra clave

- **Cluster geográfico** con **K-Means** (latitud/longitud) como proxy de “zona”

Salida

- Pipeline **reproducible** y validado.
- Modelo **optimizado** con una selección de features inteligente.

Obtención de los datos

- Los datos se obtuvieron mediante web scraping del portal de Tecnocasa (URL- Piso en venta en zona de Madrid).

- El script recorre las páginas del listado, extrae las URLs de cada anuncio desde el JSON embebido en el HTML y luego entra al detalle para recoger variables clave (precio, m², dormitorios, baños, ubicación, fotos, características, datos energéticos y POIs).

- Finalmente, consolida los registros en un DataFrame y los exporta a CSV para el EDA y el modelado.

Compresión y limpieza

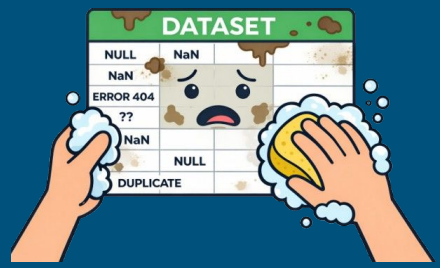

- Se revisa el esquema y la calidad de los datos: variables simples y campos semiestructurados.
- Definición del target: El precio venía dentro de un diccionario. Se extrae y se limpia, ignorando las features relacionadas para evitar data leakage.
- Normalización de datos numéricos.
- Conversión de estructuras a variables:
  - POIs: por cada categoría se genera cantidad y distancia mínima; si no hay POIs se imputa 10.000 m para representar ausencia.
  - Energía: se extrae clase/eficiencia/emisiones y se crea categoría.
  - Features: se extrae atributos clave (planta, ascensor, calefacción, aire acondicionado, fotos, planos, realista) y se normalizan.

Clustering no supervisado

- Ante la ausencia de una variable explícita de barrio/zona, se genera una variable geográfica proxy mediante K-Means sobre latitud y longitud.
- Preprocesado: estandarización de coordenadas (*StandardScaler*).
- Selección de k: se evalúan varios valores con inercia (método del codo) y silhouette score, y se valida con inspección visual.
- Decisión final: se elige k = 6 por mejor equilibrio entre separación e interpretabilidad (coherencia espacial en Madrid).
- Se creó la nueva feature cluster (zona) y se incorporó al modelo de regresión.

Clustering no supervisado

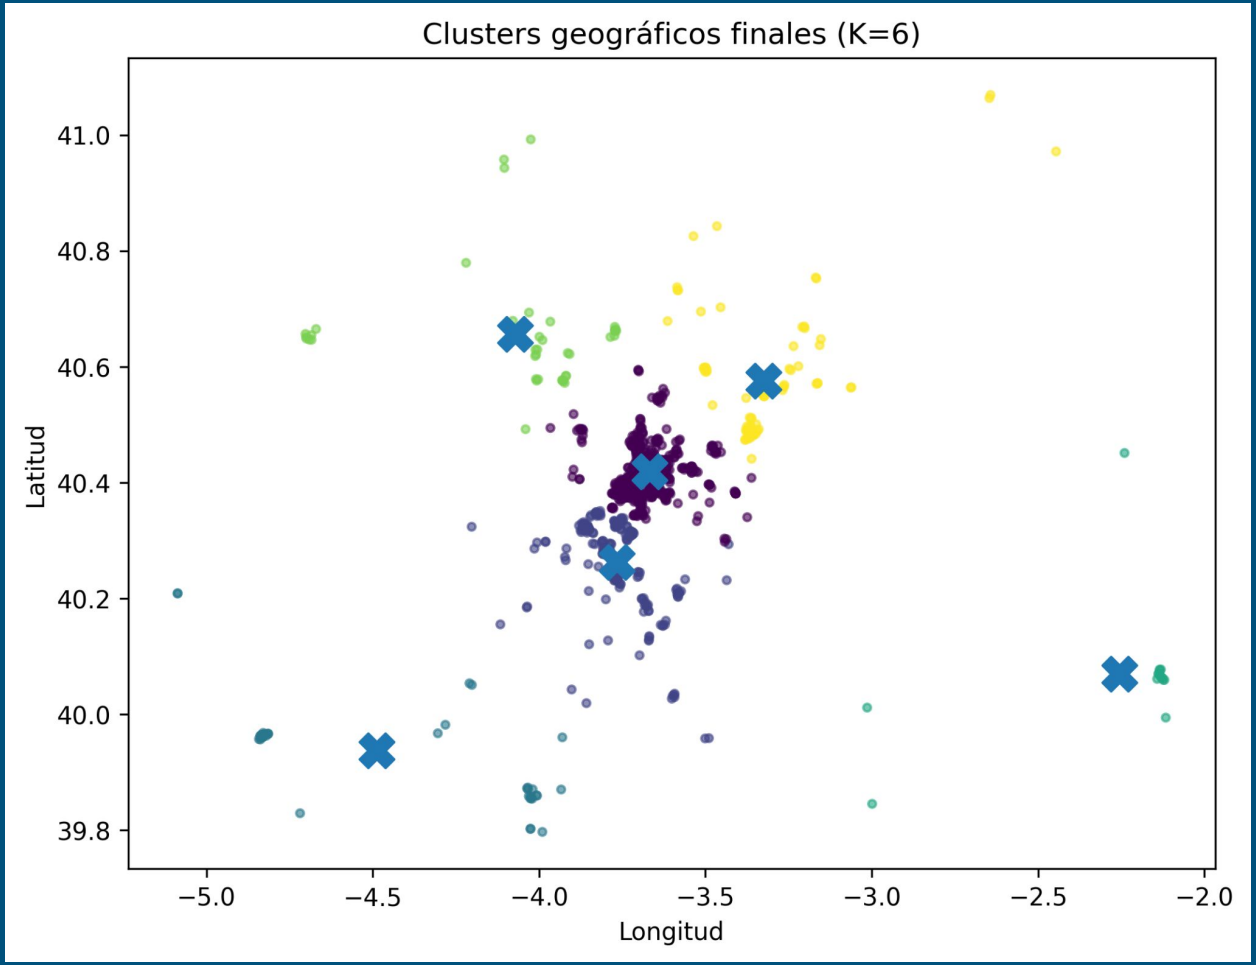

MiniEDA

- Distribución del target: histograma de precio → cola derecha y outliers (justifica trabajar con precio_log en el modelado).
- Bivariante (categóricas vs target): histogramas/densidades por categoría para detectar separación o solapamiento.
- Bivariante (numéricas vs target): correlaciones Pearson/Spearman (Spearman como referencia) + matriz de correlación para colinealidad (POIs).
- Resultado: clasificación operativa de *features* por interés (alto / moderado / bajo) para guiar selección y contrastar con eliminación por métrica.

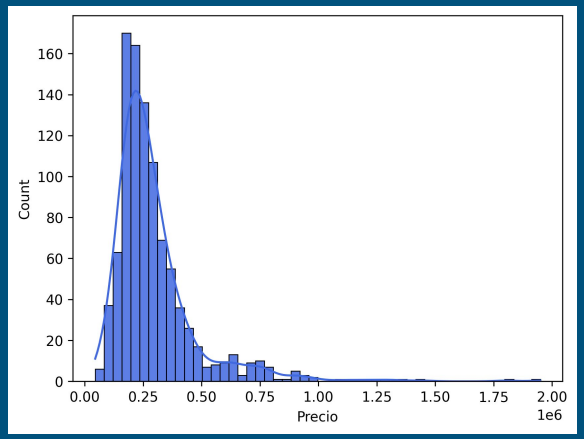

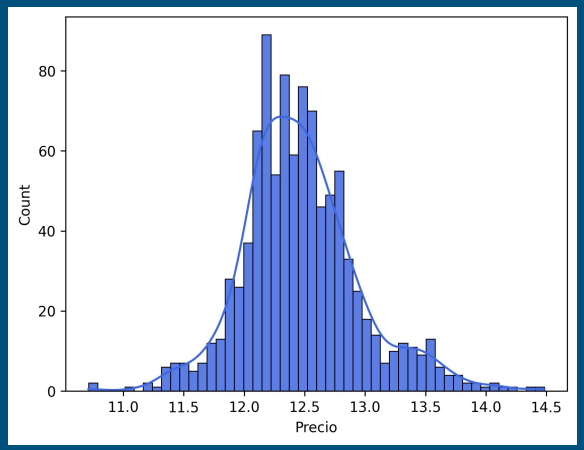

Clasificación de las variables

- ***Alto interés:*** baños, dormitorios, categoria_ord, ascensor; superficie_m2, latitud.

- ***Interés moderado:*** calefacción, clase_energetica_ord, transporte_publico, hospitales, cluster; fotografias, planta, eficiencia_energetica, POIs (resto_min_dist_m, tp_min_dist_m, hosp_min_dist_m, fca_min_dist_m, tda_min_dist_m, super_min_dist_m, bar_min_dist_m, esc_min_dist_m).

- ***Bajo interés:*** aire_acondicionado, planos, tiene_certificado, realista, tipo calefacción gas/eléctrica, resto de POIs; emisiones_energeticas, longitud, ano_construccion.

Comparación de modelos y métricas

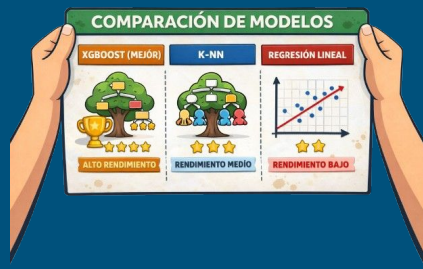

- Evaluación: MAPE (error porcentual) para comparar en términos relativos y ser más robustos ante la cola derecha/outliers del precio.
- Pipeline reproducible: ColumnTransformer + Pipeline
  - Numéricas: imputación por mediana
  - Categóricas: imputación por moda + OneHotEncode.
- Preprocesado según modelo:
  - Sin escalado para modelos basados en árboles/boosting
  - Con StandardScaler para modelos sensibles a escala

RESULTADO FINAL:

model	mean_MAPE
LGBMRegressor	1.686341e-01
CatBoostRegressor	1.692914e-01
XGBRegressor	1.805530e-01
RandomForest	2.047342e-01
DecisionTree	2.474060e-01
knn_reg_5	2.627139e-01
knn_reg_3	2.751731e-01
lr_reg	1.179826e+19

Ajuste de hiperparámetros

- Tras el *baseline*, se seleccionan los 3 mejores modelos: XGBoost, LightGBM y CatBoost.

- Se realiza el tuning de hiperparámetros con Optuna para optimizar MAPE manteniendo el mismo esquema de validación.

- Para elegir el modelo final se evalúa contra test:
  - y_real vs y_predicho (alineación visual)
  - tiempo de entrenamiento/predicción (coste computacional).

- Con el balance rendimiento + estabilidad visual + tiempo, se eligió XGBoost como modelo final para la evaluación definitiva.

Ajuste de hiperparámetros

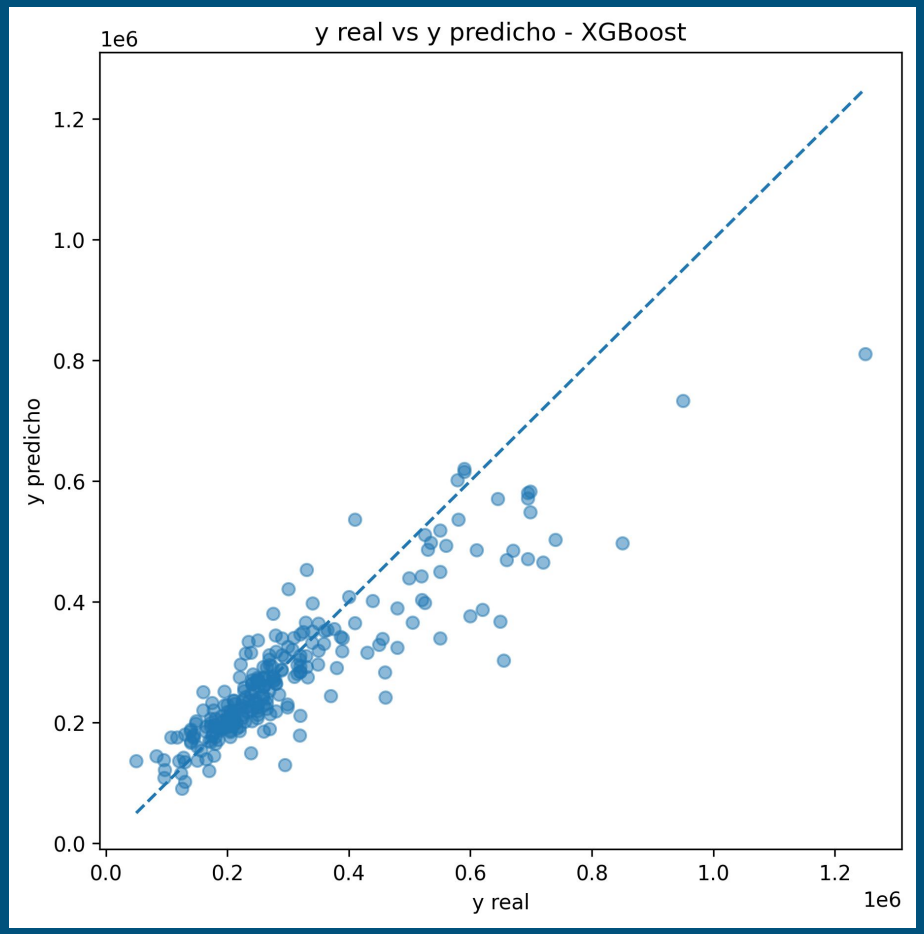

- La mayor parte de los puntos se alinea con la diagonal → **buena calibración** del modelo.
- La dispersión aumenta en precios altos (cola derecha) → **outliers** y menor densidad de ejemplos.
- Tendencia a **subestimar** algunos inmuebles muy caros y **sobreestimar** algunos intermedios.

Eliminación de *features*

- Se parte del modelo base (XGBoost) y se estima el aporte marginal de cada variable.
- Procedimiento: eliminación iterativa
  - En cada iteración se elimina 1 feature
  - Se vuelve a entrenar el modelo y se registra MAPE + tiempo
- Objetivo: encontrar cuántas variables pueden quitarse sin degradar (o incluso mejorando) la métrica y con menor coste computacional.
- Luego se compara el orden de eliminación con la clasificación del Mini EDA (alto / moderado / bajo interés).

Eliminación de *features*

- El gráfico muestra el **MAPE** obtenido al eliminar cada variable frente al tiempo de entrenamiento.

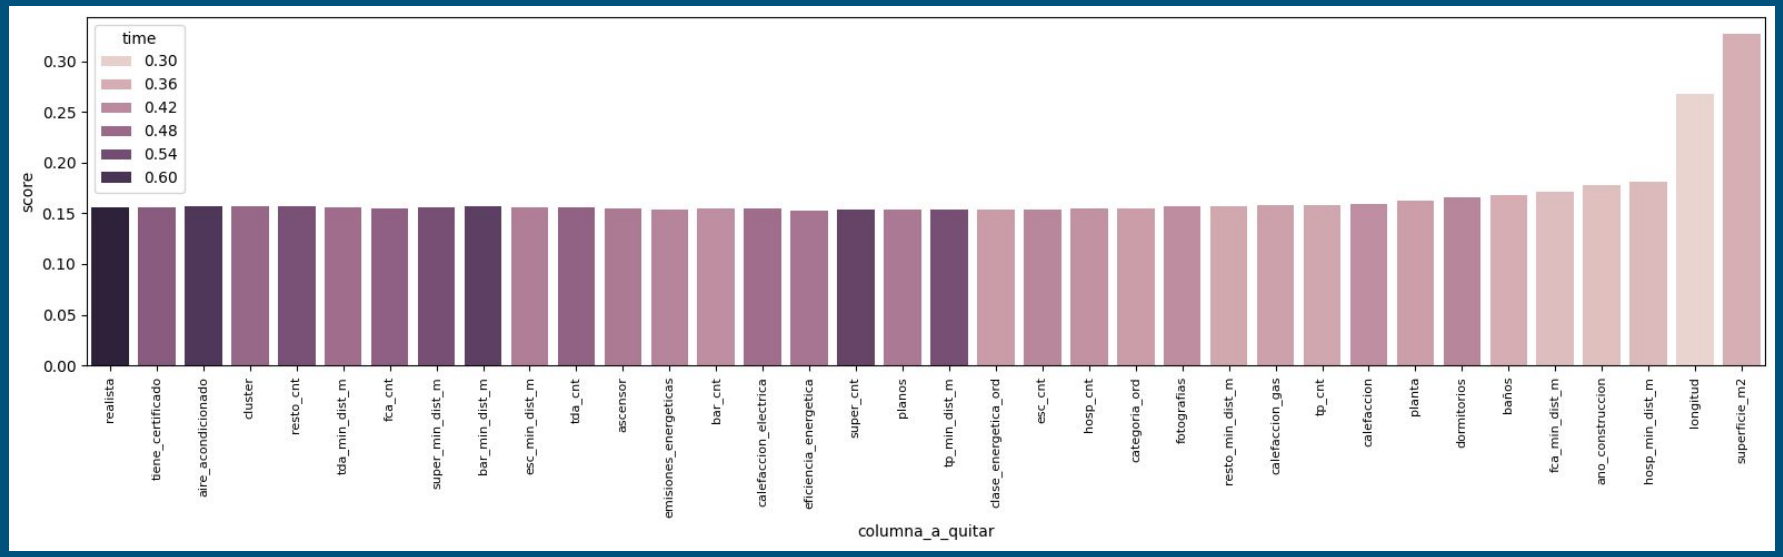

Conclusión final

- La eliminación basada en rendimiento confirma que parte de las variables catalogadas como bajo interés en el EDA aportan poca señal marginal en el modelo final.

- También evidencia que el EDA por sí solo no alcanza: variables con señal “moderada” pueden eliminarse si están correlacionadas con otras (redundancia), especialmente en bloques como energía y POIs.

- Las variables que sostienen el rendimiento hasta etapas finales son las más “estructurales” y estables: superficie_m2 (la más crítica) y, en segundo plano, variables como baños/dormitorios y ubicación/proxies.

- Resultado práctico: se puede obtener un modelo más simple y eficiente manteniendo el desempeño, combinando (1) EDA para hipótesis iniciales y (2) validación por métrica para selección final.